

## ТЗ кейса для HackAlem AI

**Направление:** Аналитика и принятие решений / Кибербезопасность и комплаенс

**Формат:** командная разработка, 5 часов

**Данные:** предоставляются в начале хакатона, обезличенные

### 1. Название

**Граф денег: восстановление финансовой структуры организованной группы по транзакционной сети**

### 2. Проблема

Сейчас **AML-аналитик банка второго уровня** сталкивается с тем, что по итогам оперативной информации ему известен только **нижний уровень** преступной цепочки — конкретные клиенты, получавшие деньги, связанные с незаконным оборотом наркотиков. Кто стоит выше — кто собирает эти деньги, через кого их прогоняют и кто в итоге ими распоряжается — приходится восстанавливать вручную.

Из-за чего:

| Последствие                                              | Масштаб                                                           |
|----------------------------------------------------------|-------------------------------------------------------------------|
| Ручная трассировка цепочки от одного клиента на 4 колена | часы работы аналитика на один узел                                |
| Основная часть сети остаётся невидимой                   | известен 81 клиент, реальная сеть — <b>2 248 узлов</b>            |
| Блокируется только нижний уровень                        | организаторы сохраняют инфраструктуру и восстанавливают её за дни |
| Решения о приоритете проверки принимаются интуитивно     | нет ранжирования, кого смотреть первым                            |

**Эффект от решения:** аналитик за минуты получает ранжированный список узлов с обоснованием роли каждого, вместо недель ручной трассировки; фокус проверки смещается с 81 «курьера» на реальные точки консолидации.

### 3. Пользователь

**Основной пользователь:** AML-аналитик / специалист подразделения финансового мониторинга банка второго уровня.

**Ключевой сценарий (от входа до результата):**

1. Аналитик получает от правоохранительных органов список клиентов, проходящих по делу (81 gid).
2. Загружает выгрузку исходящих переводов этих клиентов на 4 колена в инструмент команды.
3. Инструмент строит граф, считает метрики и **присваивает каждому узлу роль**: точка консолидации, транзит, распределитель, конечный получатель, периферия.
4. Аналитик видит схему сети с направлением потоков, подсветкой ролей и кластерами.

5. Аналитик открывает **топ-лист приоритетов**, читает обоснование по каждому узлу («получает от 11 разных плательщиков, отдаёт дальше 3% полученного») и формирует перечень клиентов на углублённую проверку и запрос в правоохранительные органы.

## 4. Задача

Разработать **аналитический инструмент (пайплайн + интерфейс просмотра)**, который по графу транзакций определяет роли участников финансовой сети и ранжирует их по значимости, и выдаёт аналитику готовую к работе модель структуры группы: участники, связи, направление денег, транзитные узлы, точки консолидации, кластеры, ключевые узлы.

Инструмент должен отвечать на вопрос аналитика: **«кого из этих 2 248 клиентов смотреть первым и почему»**.

## 5. Вход → выход

### Вход

| Параметр | Значение                                                           |
|----------|--------------------------------------------------------------------|
| Формат   | 3 файла .parquet (edges, nodes, transactions)                      |
| Объём    | 2 248 узлов, 3 119 рёбер, 4 840 транзакций                         |
| Период   | 2026-07-01 — 2026-07-31                                            |
| Частота  | разовая выгрузка (батч), онлайн-поток не требуется                 |
| Пример   | предоставляется полный датасет, схема полей — в README.md датасета |

### Выход

Три CSV-выгрузки фиксированной схемы + экран просмотра.

**nodes\_roles.csv** — строка на каждый из 2 248 узлов:

| Колонка        | Тип   | Смысл                                                    |
|----------------|-------|----------------------------------------------------------|
| gid            | int64 | идентификатор клиента                                    |
| role           | str   | основная роль из словаря (см. ниже)                      |
| role_score     | float | уверенность в роли, 0–1                                  |
| cluster_id     | int   | номер кластера                                           |
| priority_score | float | приоритет для аналитика, 0–1                             |
| evidence       | str   | почему присвоена роль — до 200 символов, человекочитаемо |

**Словарь ролей** (обязательный минимум; команда может расширить, задокументировав):

| Роль         | Смысл                                                               |
|--------------|---------------------------------------------------------------------|
| consolidator | точка консолидации — аккумулирует средства от нескольких участников |
| transit      | транзитный счёт — пропускает средства дальше, не удерживая          |

| Роль        | Смысл                                              |
|-------------|----------------------------------------------------|
| distributor | веерное распределение средств на много получателей |
| terminal    | конечный получатель — деньги приходят и остаются   |
| coordinator | координирующий узел, кандидат в организаторы       |
| peripheral  | периферия, признаков роли не выявлено              |

**clusters.csv** — строка на кластер: cluster\_id, n\_nodes, n\_seed, sum\_kzt\_internal, top\_gids, hypothesis (гипотеза о назначении кластера).

**top\_nodes.csv** — ранжированный список **не менее 20** узлов: rank, gid, role, priority\_score, why (обоснование текстом).

**Экран просмотра:** схема сети с направлением потоков, подсветкой ролей/кластеров и поиском по gid. Веб-страница, ноутбук или desktop — на усмотрение команды.

**Допустимая задержка:** полный пересчёт от сырых .parquet до выгрузок — **не более 5 минут** на предоставленном объёме.

## 6. Данные

**Способ доступа:** архив с папкой data/ выдаётся всем командам в начале хакатона. Внешние источники не требуются и не предполагаются.

### Состав

| Файл                 | Строк | Содержание                                                                           |
|----------------------|-------|--------------------------------------------------------------------------------------|
| edges.parquet        | 3119  | пара плательщик→получатель, агрегированная за период: src, dst, sum_kzt, n_tx, depth |
| nodes.parquet        | 2248  | уникальный клиент: gid, depth (минимальное колено), is_seed                          |
| transactions.parquet | 4840  | отдельная транзакция: src, dst, date, sum_kzt                                        |

Полное описание полей — в README.md датасета.

### Как собран граф

- стартовые вершины — 81 клиент, ранее выявленный как участник незаконного оборота наркотиков;
- прослеживаются **только исходящие** переводы, глубина обхода — **4 колена**;
- порог: транзакции **< 5 000 KZT не попали в выгрузку**;
- только внутрибанковские переводы, июль 2026.

Распределение по коленам: seed — 81, 1-е — 472, 2-е — 462, 3-е — 789, 4-е — 444.

Суммарный оборот в графе: **365 890 012 KZT**.

## Качество и ограничения данных (объявлены заранее — их учёт оценивается)

| Особенность                                                                                                                          | Что это значит для решения                                                                           |
|--------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| <b>Обрыв на 4-м колене.</b> 444 узла имеют depth=4 и нулевые исходящие — это артефакт обхода, а не «деньги осели»                    | наивный признак «out_degree = 0 ⇒ конечный получатель» даст 444 ложных «сток»                        |
| <b>Только исходящие переводы.</b><br>Входящие потоки на узлы за пределами выборки не видны                                           | нельзя достоверно считать полный баланс узла                                                         |
| <b>У seed-клиентов входящие суммы занижены</b> — граф собран <i>от</i> них, деньги, полученные ими извне выборки, в данные не попали | отношение «отдал / получил» у seed некорректно; 354 узла графа отдают больше, чем по данным получили |
| <b>Порог 5 000 KZT</b>                                                                                                               | дробление ниже порога в данных невидимо                                                              |
| <b>19 из 81 seed отсутствуют в рёбрах</b> , ещё 12 присутствуют только как получатели                                                | 31 seed не имеет исходящих переводов — учитывать при обходе                                          |
| <b>16 слабосвязных компонент:</b> 1 877 узлов (46 seed), 270 (1 seed), остальные 14 — от 2 до 17 узлов                               | сеть не монолитна, 352 узла вне крупнейшей компоненты                                                |
| <b>Нет атрибутов клиента</b> — ни ФИО, ни возраста, ни типа операции, ни остатков                                                    | только структура и суммы                                                                             |
| <b>Нет размеченных ролей (ground truth)</b>                                                                                          | оценка — по обоснованности критериев, а не по ассигасу                                               |

**Лицензия и приватность:** данные обезличены (gid — синтетический идентификатор без привязки к личности), предоставляются исключительно для использования в рамках хакатона.

## 7. Must have

Без этих пяти пунктов решение не считается выполненным. К каждому — способ проверки.

| № | Обязательная функция                                                                                            | Как проверяется                                                                                                   |
|---|-----------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| 1 | <b>Воспроизводимый пайплайн.</b> Один запуск от сырых .parquet до всех трёх выгрузок, без ручных шагов          | Жюри запускает команду из README на чистой машине; пайплайн отрабатывает < 5 минут и создаёт 3 файла              |
| 2 | <b>Роль и скор у каждого узла.</b> Все 2 248 узлов получили роль из словаря, role_score и evidence              | nodes_roles.csv содержит 2 248 строк, все обязательные колонки заполнены, evidence непустой                       |
| 3 | <b>Критерии ролей задокументированы и объяснимы.</b> Для каждой роли — формальное правило или метрика с порогом | Жюри называет 3 произвольных gid; команда за минуту объясняет, почему роль именно такая, опираясь на свои метрики |

| № | Обязательная функция                                                                                                                                         | Как проверяется                                                                                         |
|---|--------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| 4 | <b>Кластеризация сети.</b> Узлы разбиты на группы, по каждому кластеру — размер, число seed, оборот и гипотеза                                               | clusters.csv заполнен; cluster_id есть у каждого узла в nodes_roles.csv                                 |
| 5 | <b>Топ-лист приоритетов + визуализация.</b> Ранжированный список $\geq 20$ узлов с обоснованием и экран со схемой сети, где видно направление потоков и роли | top_nodes.csv заполнен; на демо жюри называет gid — команда находит его на схеме и показывает его связи |

## 8. Опционально

Дают дополнительные баллы, сдачу не блокируют:

- **Учёт артефакта обрыва графа** — отделение настоящих конечных получателей от узлов, «обрезанных» 4-м коленом, с обоснованием метода.
- **Временные паттерны** — сквозной транзит (пришло и ушло в течение 1–2 дней), всплески активности, синхронные переводы от нескольких плательщиков в один день.
- **Поиск повторяющихся маршрутов и возвратных потоков** — устойчивые цепочки  $A \rightarrow B \rightarrow C$  и циклы, где деньги возвращаются к отправителю.
- **Детекция аномалий** — дробление сумм, аномальные профили узлов относительно их колена (правила или ML-модель).
- **Оценка устойчивости сети** — что произойдёт с сетью при изъятии топ-N узлов; распадается ли она на изолированные фрагменты.
- **AI-ассистент аналитика** — вопрос на естественном языке («кто собирает деньги с этих пятерых?») → ответ по графу со ссылками на узлы.
- **Автогенерация карточки узла** — краткая справка по клиенту: роль, потоки, связи, на что обратить внимание.
- **Оценка полноты** — указание, каких данных не хватает, чтобы закрыть белые пятна, и какой запрос аналитику стоит сделать следующим.

## 9. Ограничения

### Нельзя

- **Хардкодить результат** — зашитые в код списки gid под «правильный ответ» вместо расчёта.
- **Сдавать «чёрный ящик»** — роль без объяснимого правила или интерпретируемых признаков не засчитывается (см. must have 3).
- **Обогащать внешними источниками** и достраивать атрибуты клиентов, которых нет в данных (пол, возраст, доход, организация) — любые такие поля будут считаться выдумкой.
- **Требовать облачный кластер, GPU-обучение или платные сервисы** для воспроизведения результата.

### Обязательно учесть

| Требование            | Что это значит                                                                                              |
|-----------------------|-------------------------------------------------------------------------------------------------------------|
| <b>Explainability</b> | каждая роль и каждая позиция в топ-листе сопровождается обоснованием, понятным аналитику без ML-образования |
| <b>Приватность</b>    | данные обезличены; решение не должно предполагать работу с ФИО, ИИН или иными персональными данными         |

| Требование                       | Что это значит                                                                                                     |
|----------------------------------|--------------------------------------------------------------------------------------------------------------------|
| <b>Осторожность формулировок</b> | выводы формулируются как <b>гипотезы для проверки</b> («признаки консолидации»), а не как утверждение о виновности |
| <b>Производительность</b>        | полный пересчёт $\leq 5$ минут на предоставленном объёме, локально, на обычном ноутбуке                            |
| <b>Инфраструктура</b>            | всё работает локально; интернет может потребоваться только для внешнего LLM API, если команда его использует       |
| <b>Стек</b>                      | любой язык и библиотеки; рекомендуется Python (pandas, networkx/igraph) — стартовый код предоставляется            |
| <b>Масштабируемость</b>          | в README указать, что изменится в подходе при росте графа до ~1 млн узлов (текстом, реализация не требуется)       |

## 10. Артефакты

| Артефакт             | Обязателен | Содержание                                                                                                                       |
|----------------------|------------|----------------------------------------------------------------------------------------------------------------------------------|
| <b>Репозиторий</b>   | да         | исходный код пайплайна и интерфейса                                                                                              |
| <b>README</b>        | да         | как запустить (одна команда), описание критериев ролей и порогов, что на выходе, ограничения подхода, раздел про масштабирование |
| <b>Выгрузки</b>      | да         | nodes_roles.csv, clusters.csv, top_nodes.csv                                                                                     |
| <b>Схема решения</b> | да         | один слайд/диаграмма: данные → метрики → роли → интерфейс                                                                        |
| <b>Демо</b>          | да         | 5 минут: живой прогон и разбор 2–3 узлов по существу                                                                             |

**Стартовый код** (загрузка данных, сборка графа, базовые метрики, шаблоны выгрузок) предоставляется организаторами в папке `starter/` — чтобы команды не тратили час из пяти на boilerplate.

## Примечание для организаторов

Кейс проверен на данных: заявленные must-have выполнимы за 5 часов командой из 3–4 человек. В данных присутствуют выраженные кандидаты на все роли словаря — узлы с входящими переводами от 8–24 разных плательщиков, узлы с веерной рассылкой на 60–116 получателей, 72 узла с коэффициентом пропуска 0.8–1.2, а при базовой кластеризации (Louvain) — 8 устойчивых сообществ, содержащих более одного seed-клиента. Задача имеет решение, но не имеет единственного правильного ответа — это заложено намеренно, оценка идёт по обоснованности критериев.

| Критерий                                    | Что оцениваем                                                                                                                                                                                                                                      | Баллы |
|---------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------|
| Соответствие задаче и работоспособность     | Оценивается, насколько решение соответствует поставленной задаче и позволяет реализовать основной заявленный сценарий.                                                                                                                             | 25    |
| Техническая реализация                      | Оценивается качество технической реализации решения: выбранный подход, архитектура, взаимодействие компонентов, использование AI/agent AI и других технологий. Учитывается соответствие фактической реализации заявленной логике проекта.          | 25    |
| README и воспроизводимость                  | Оценивается, насколько документация позволяет понять устройство проекта, используемые технологии, порядок запуска и основной сценарий работы. Также учитывается возможность воспроизвести и проверить решение на основании материалов репозитория. | 25    |
| Ценность и применимость решения             | Оценивается, насколько решение отвечает обозначенной проблеме. Учитывается практическая применимость представленного подхода.                                                                                                                      | 15    |
| Потенциал развития и оригинальность подхода | Оценивается потенциал дальнейшего развития решения, его применения в более широком масштабе, а также наличие обоснованных нестандартных или оригинальных подходов к реализации задачи.                                                             | 10    |
| Итого                                       | —                                                                                                                                                                                                                                                  | 100   |